

Факультет информационных технологий и управления

Кафедра «Прикладная математика»

ЗАДАНИЕ

на научно-исследовательскую работу

Студенту Лазареву И.С.

Задание: обзор всего, что связано с рефрактометрами и машинным обучением для них.

Срок выполнения: « 24 » февраля 2026 г.

Руководитель Данилина Э.М.

Задание к выполнению принял студент Лазареву И.С.

Дата выдачи задания: « 9 » февраля 2026г.

СОДЕРЖАНИЕ

СОДЕРЖАНИЕ	3
ВВЕДЕНИЕ.....	4
1. ВВОДНАЯ ЧАСТЬ	5
1.1 Актуальность исследования.....	5
1.2 Цель и задачи исследования	7
2. ОСНОВНАЯ ЧАСТЬ	9
2.1 Физические основы рефрактометрии и типы выходных данных ..	9
2.2 Классические методы калибровки и их ограничения	10
2.3 Постановка задачи машинного обучения для рефрактометрических данных	12
2.4 Обзор применимых методов машинного обучения	13
2.5 Описание собственной разработанной ML-модели	15
3. ПРОГРАММА	17
3.1 Подготовка тестовых данных	17
3.2 Проведение тестирования	18
3.3 Анализ результатов тестирования.....	19
ЗАКЛЮЧЕНИЕ	20
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	21

ВВЕДЕНИЕ

**ВСЕ ФОРМАТЫ И СТИЛИ НАСТРОЕНЫ, РАБОТАТЬ ИМЕННО
В ЭТОМ ДОКУМЕНТЕ!!!**

Во введении описывается актуальность исследования, и задачи, которые предполагается решить, а также методы решения.

Инфа: 1. Уравнение выведено (практика)

1. ВВОДНАЯ ЧАСТЬ

1.1 Актуальность исследования

Современное машиностроение и смежные отрасли предъявляют повышенные требования к стабильности технологических процессов, качеству обрабатываемых поверхностей и ресурсоэффективности. Существенное влияние на эти показатели оказывает состояние смазочно-охлаждающих жидкостей (СОЖ): они обеспечивают смазку зоны резания, отвод тепла и удаление стружки, снижают износ инструмента и влияют на шероховатость детали [1]. В ходе эксплуатации изменяются концентрация и химический состав рабочей эмульсии или раствора вследствие испарения воды, механического загрязнения, роста микробной флоры и деградации добавок; это снижает эффективность СОЖ и ведёт к росту затрат и риску брака. Следовательно, оперативный, воспроизводимый и по возможности автоматизированный контроль концентрации остаётся актуальной инженерной задачей.

Традиционные лабораторные методы (титриметрия, «ручная» рефрактометрия со считыванием шкалы оператором) часто характеризуются длительностью цикла и не всегда укладываются в ритм серийного производства. Перенос измерения в зону эксплуатации и регистрация сигнала в цифровой форме создают предпосылки для встроенной аналитики и накопления корпуса данных, на основе которого применимы методы машинного обучения [4, 5]. Рефрактометрический канал, измеряющий показатель преломления или прокси-характеристики, связанные с распределением интенсивности в приёмной плоскости, относится к числу компактных средств контроля [7]. Однако устойчивая интерпретация цифровой кривой сигнала — локализация границы «свет — тень», извлечение устойчивых численных признаков — чувствительна к условиям измерения, загрязнению оптики и неоднородности образца; жёстко заданные пороговые правила плохо переносятся между партиями жидкости и версиями прошивки без повторной настройки.

Отдельную проблему представляет подготовка обучающих данных для регрессионной модели. В реальных измерительных сериях встречаются кривые засветки с артефактами: локальные провалы и всплески, смещение фронта, неполное пересечение с выбранными уровнями сигнала. Включение таких реализаций в датасет без фильтрации искажает оценку зависимости «форма кривой — концентрация» и ведёт к некорректному обучению. В классическом контуре оператор вручную отбирает допустимые записи и задаёт линии/уровни; автоматизация этого этапа с помощью обучаемого классификатора качества кривых согласуется с практикой контроля качества данных (data-centric ML) и снижает трудоёмкость разметки [4, 5].

Накопление сеансов измерений с известными метками концентрации позволяет построить регрессионную модель, связывающую параметры кривой с концентрацией [2, 3, 5]. Сочетание регрессии для оценки концентрации и классификации (или обнаружения аномалий) для отсева дефектных кривых отражает распространённый инженерный подход к спектральным и профильным данным [12, 13]. В прикладной литературе отмечаются случаи повышения точности измерения показателя преломления и связанных величин за счёт моделей машинного обучения по полному спектру или по многоканальным признакам [12, 13], а также примеры интеграции рефрактометрии в контур аналитических технологий с прогнозированием по данным процесса [14]. Эти работы подтверждают, что ML не заменяет физику прибора, но позволяет устойчивее извлекать целевую информацию из зашумлённого цифрового представления сигнала.

Таким образом, актуальность настоящей работы определяется сочетанием производственной значимости контроля СОЖ [1], ограничений эвристической обработки рефрактометрического сигнала, потребности в автоматизации отбора качественных кривых для обучения и в программном комплексе полного цикла — от разбора измерительных записей до валидации модели и выгрузки калибровочных параметров.

1.2 Цель и задачи исследования

Цель работы — разработать и программно реализовать подход к оценке концентрации по цифровым кривым засветки рефрактометрического канала с использованием градиентного бустинга, а также обосновать и описать схему автоматического отбора кривых, пригодных для обучения, на основе классификатора качества; представить результаты тестирования на отложенной и независимой выборках.

Для достижения цели поставлены следующие задачи:

Систематизировать физические основы рефрактометрии и типы выходных данных цифрового канала.

Проанализировать классические подходы к калибровке и их ограничения в условиях дрейфа оптики и изменения состава жидкости.

Сформулировать постановку задачи машинного обучения: регрессия концентрации по вектору признаков, построенному из пересечений кривой с фиксированными уровнями сигнала относительно опорной кривой сеанса.

Обозреть применимые методы ML: регрессия (в т. ч. бустинг), бинарная классификация качества кривой, методы обнаружения аномалий как альтернатива классификации при дефиците размеченных отрицательных примеров.

Описать реализованную регрессионную модель (CatBoost), конвейер подготовки данных и предлагаемую архитектуру классификатора отбора кривых для подготовки датасета.

Провести подготовку тестовых данных, тестирование модели и анализ метрик качества (RMSE, MAE, R^2) и согласованности с эталонной измерительной сессией.

Объект исследования — цифровые измерительные записи рефрактометрического канала. Предмет исследования — методы и программные средства построения регрессионной модели оценки концентрации, подготовки калибровочных данных и контроля качества входящих в обучение кривых.

2. ОСНОВНАЯ ЧАСТЬ

2.1 Физические основы рефрактометрии и типы выходных данных

Показатель преломления n характеризует отношение скорости распространения монохроматической электромагнитной волны в вакууме к скорости в среде; для непоглощающей среды он связан с диэлектрической проницаемостью и (в общем случае) с поляризацией среды [7]. На границе двух прозрачных сред с показателями n_1 и n_2 законы Снеллиуса связывают углы падения θ_1 и преломления θ_2 :

$$n_1 \sin \theta_2 = n_2 \sin \theta_1, \quad (1)$$

Если свет падает из более «оптически плотной» среды (больше n) на границу с менее плотной, существует предельный угол полного внутреннего отражения $\theta_{cr} = \arcsin\left(\frac{n_2}{n_1}\right)$ при $n_1 > n_2$. В ряде рефрактометрических схем, включая классические критические и полукритические конфигурации, измеряемая величина связана с положением границы светотени или с углом, при котором выполняется условие критического поведения луча; именно поэтому форма и стабильность кривой интенсивности в приёмной плоскости несёт информацию о n и, косвенно, о концентрации.

Дисперсия и полихроматичность реальных источников приводят к тому, что «один» показатель преломления на практике уточняется по длине волны; в лабораторных приборах это учитывают выбором спектрального диапазона и температурной стабилизацией. Для инженерного контроля растворов, в том числе и СОЖ, часто используют монотонную эмпирическую связь между измеряемым оптическим показанием и концентрацией при фиксированном или скорректированном температурном режиме.

Типы рефрактометров. Лабораторские приборы типа Аббе дают высокую точность при ручном визировании границы и известны из курсов оптики и приборостроения. Портативные цифровые рефрактометры ориентированы на быстрые измерения в полевых условиях и обычно выдают уже пересчитанную величину, например, индекс преломления или «градусы

Брикса» для сахаросодержащих сред, по внутренней калибровке. Промышленные врезные рефрактометры контролируют поток жидкости непрерывно; им важны дрейф нуля, загрязнение оптического окна и пузырьки — всё это отражается на форме регистрируемого сигнала. Волоконно-оптические рефрактометрические схемы используются в датчиках среды и в исследованиях, где важна компактность и помехоустойчивость; в таких работах нередко появляется полный спектральный отклик или многоточечная регистрация, что стимулирует применение методов машинного обучения по «обогащённому» цифровому представлению [12, 13].

Цифровой выход прибора в рассматриваемой постановке представляет собой одномерную дискретную кривую — вектор отсчётов $y = (y_0, y_1, \dots, y_{N-1})^T, y_j \geq 0$, полученный в одном сеансе измерения; N определяется аппаратной развёрткой (число элементов линейки, шаг оцифровки). Помимо массива y , в записи сеанса присутствуют служебные поля (идентификатор пробы, концентрация, при необходимости температура и др.). Дальнейшая обработка относится к классу анализа одномерных сигналов и может опираться на методы цифровой обработки сигналов и изображений при интерпретации засветки как профиля яркости [8].

Геометрически кривая засветки отражает переход интенсивности вдоль координаты развёртки; устойчивые точки привязки, положение максимального наклона, пересечения с фиксированными уровнями, интегральные характеристики фронта, служат признаками для последующих моделей. Именно на уровне этих признаков удобно отделять «типичную» форму от аномальной: классификация качества линии опирается не на субъективное «на глаз», а на согласованный численный вектор признаков.

2.2 Классические методы калибровки и их ограничения

Классический подход к прибору с монотонной шкалой «показание — концентрация» включает лабораторное построение таблицы опорных точек (c_k, u_k) , где u_k — показание датчика шкала, код АЦП, положение границы, и

последующую интерполяцию для промежуточных значений. Линейная или кусочно-линейная аппроксимация в узких диапазонах часто достаточна; при существенной нелинейности применяют полиномиальные или сплайновые модели. В пищевой и химической практике широко распространены шкалы в градусах Брикса и родственные пересчёты массовой доли сухого вещества; для точных измерений критична температурная поправка и однородность пробы.

Ограничения классики при переходе к полной цифровой кривой засветки многообразны. Во-первых, выбор одного скалярного показания и сводит форму кривой к одному числу: при дрейфе оптики или изменении освещённости смещается весь профиль, и одна контрольная точка даёт систематическую ошибку, хотя человек по графику мог бы заметить «подозрительную» форму. Во-вторых, фиксированные пороги на отсчётах u_j чувствительны к шуму и локальным артефактам. В-третьих, ручной отбор «хороших» записей для таблицы плохо масштабируется при росте числа сеансов и не переносится между операторами одинаково. В-четвёртых, согласование с встроенным ПО датчика требует явного описания опорных уровней и формата конфигурации — отсюда практика нескольких горизонтальных уровней сигнала и векторных признаков вместо одной точки.

С точки зрения подготовки данных для машинного обучения классическая калибровка остаётся физическим и нормативным ориентиром (что именно мы хотим измерять), но не исчерпывает средств контроля качества самой кривой. Отсюда логично выделяется отдельная задача: до любой регрессии концентрации или построения расширенной калибровочной таблицы отфильтровать записи с искажённой засветкой — то есть перейти от ручной метки «плохая линия» к обучаемому классификатору.

Указанные ограничения мотивируют многомерное описание кривой и статистические модели на корпусе измерений, а также явный контроль качества входа: «сначала классификация пригодности, затем — задачи оценки концентрации» [4, 5].

2.3 Постановка задачи машинного обучения для рефрактометрических данных

Настоящая работа в части практической реализации опирается на бинарную классификацию качества кривой засветки. Пусть на вход алгоритма поступает кривая $y = (y_0, \dots, y_{N-1})^T$ и контекст сеанса (опорная кривая $y^{(0)}$, набор уровней $L_1, \dots, L_M$). По кривой строится вектор признаков $\varphi(y) \in \mathbb{R}^d$. Метка $\omega \in \{0, 1\}$ интерпретируется так: $\omega = 1$ — «хорошая линия» (пригодна для включения в датасет обучения последующих моделей), $\omega = 0$ — «плохая линия» (артефакт, нестабильный фронт, неполные пересечения и т. п.). Требуется построить классификатор $g: \mathbb{R}^d \rightarrow [0, 1]$, аппроксимирующий $P(\omega = 1 | \varphi)$ (или дискретное решение $\hat{g}(\varphi) \in \{0, 1\}$ при фиксированном пороге на вероятности).

Обучающая выборка для классификации: $D_{cls} = \{(\varphi^{(k)}, \omega^{(k)})\}$. Эмпирический риск с логистической потерей для параметрического классификатора сводится к максимизации логарифма правдоподобия: минимизации кросс-энтропии [4, 5]; для деревьев и бустинга оптимизируется выбранная в библиотеке функция потерь (Logloss для CatBoostClassifier [3]). На контрольной выборке используются точность, полнота, F_1 -мера по классу «хорошая», ROC-AUC, матрица ошибок; при дисбалансе классов полнота по «плохим» важна, чтобы не пропускать артефакты.

Связанная задача (регрессия концентрации). Для полноты картины сохраним формализацию признаков, используемых в смежных проектах по тому же каналу измерения. Задан набор уровней L_m . Координата пересечения кривой с уровнем L_m (линейная интерполяция между соседними отсчётами):

$$x_{m(y)} = j + \frac{(L_m - y_j)}{(y_{j+1} - y_j)}, \quad (2)$$

(если пересечение отсутствует — пропуск). Для опорной $y^{(0)}$ и текущей y вводятся относительные признаки $z_m = x_{m(y)} - x_{m(y^{(0)})}$. Регрессия $c \approx f(z)$ обучается на очищенном множестве, полученном после фильтрации $g(\varphi) \geq \tau$; метрики RMSE, MAE, R^2 и величины согласования эталона (аналогично

$\delta(c)$, $\delta_{max}(c)$ в прежних записях) применимы к этому этапу, но не к обучению классификатора в настоящей работе.

2.4 Обзор применимых методов машинного обучения

Ниже кратко систематизированы семейства методов и проиллюстрированы публикациями, где оптические измерения, близкие по духу к рефрактометрии (оценка показателя преломления, спектральный отклик, inline-контроль среды), сочетаются с машинным обучением. Это задаёт научный фон для выбора градиентного бустинга и бинарной классификации в настоящей работе.

Классификация и ранжирование. Для табличных признаков φ стандартны логистическая регрессия (линейная граница), kNN, случайный лес, градиентный бустинг (XGBoost, LightGBM, CatBoost) [2, 3, 9], многослойные сети малой глубины. В задаче «хороший / плохой» профиль важны устойчивость к шуму, работа с пропусками в признаках (если пересечение с отдельным уровнем L_m не найдено) и интерпретируемость важностей признаков — у бустинга над деревьями эти свойства проявляются на практике [3].

Регрессия. Для оценки концентрации или n по вектору признаков применяют те же бустинговые регрессоры, линейные и ядерные методы как baseline [4, 5]. В связке с классификатором регрессия естественно ставится вторым этапом после фильтрации.

Обнаружение аномалий. Если «плохих» кривых мало и разметка однобокая, полезны Isolation Forest, одноклассовый SVM, автоэнкодер по y или по φ [4, 5]. Порог отделяет хвост распределения «аномальности»; метод комбинируют с экспертной разметкой для калибровки.

Волоконный рефрактометр и машинное обучение. В работах по самореференсным волоконным рефрактометрическим схемам машинное обучение используют для снятия неоднозначности и повышения точности оценки показателя преломления по многоканальным данным датчика [12].

Смысл кейса: сам прибор даёт избыточный цифровой отклик, а ML выбирает устойчивое решение в присутствии шума и нелинейностей — близко к идее извлечения надёжных признаков из профиля засветки.

Полный спектр и ML для рефрактометрического зондирования. Публикации в журналах уровня Biosensors (MDPI) рассматривают повышение точности сенсорики показателя преломления за счёт моделей, обученных на полном спектре отклика, а не на одной длине волны [13]. Для пользователя практики важен сам факт: даже «физически мотивированный» датчик выигрывает от использования всего доступного цифрового следа измерения, что оправдывает богатый вектор признаков и отказ от одного порога.

PAT в биотехнологии. В крупных работах по аналитическим технологиям в производстве клеточных и генных терапий рефрактометрию включают в контур контроля вместе с моделями машинного обучения и метаболического моделирования: по данным процесса строятся прогнозы и связи между параметрами [14]. Кейс показывает интеграцию inline-рефрактометрии в промышленный data pipeline, где качество сырого сигнала критично для доверия к модели.

Связка рефрактометрии с предсказанием состава в пищевой/лабораторной сфере. Исследования уровня предсказания содержания этанола и экстракта по комбинации методов, включающих рефрактометрию, демонстрируют типичный сценарий «несколько физических измерений + ML» [15]. Хотя предмет отличается от СОЖ, логика та же: косвенные признаки и калибровка по данным.

Промышленный и лабораторный контекст. Для металлообработки ключевым остаётся устойчивость к загрязнению окна, пузырькам и дрейфу — то есть как раз необходимость отсеивать «плохие» кривые до любой регрессии. Литература по ML в рефрактометрии чаще фокусируется на точности оценки n или состава, но методологически вывод один: цифровой след измерения должен обрабатываться устойчивыми моделями, а качество входа — контролироваться.

Для практики с кривыми засветки обоснован выбор градиентного бустинга CatBoost в задаче бинарной классификации по табличным признакам φ с возможным включением пропусков; регрессия концентрации по z остаётся логичным следующим шагом на очищенных данных.

2.5 Описание собственной разработанной ML-модели

Программная инфраструктура разбора измерений (Python3, NumPy, pandas [6]) опирается на представление кривой как массива отсчётов и вычисление геометрических характеристик. В реализованном CLI-конвейере для каждой кривой формируется вектор признаков φ из двух компонентов:

(1) k — максимальный по модулю наклон, характеризует «резкость» фронта;

(2) `assurasy_of_line` — число провалов на профиле, вычисляемое как количество локальных минимумов на сглаженной версии кривой, с управляемым окном сглаживания и с порогом по глубине провала. Такой признак отражает степень «изрезанности» профиля: артефакты, пузырьки, нестабильная засветка, и формализует экспертное правило «линия должна быть гладкой».

Модель: CatBoostClassifier [3] (логистическая потеря, число итераций T , скорость обучения η , глубина деревьев при необходимости). Разбиение на обучение и контроль — стратифицированное при дисбалансе классов; метрики: ROC-AUC, F_1 для класса «хорошая», матрица ошибок.

Разметка обучающей выборки: мы присваиваем каждой кривой метку ω по критериям «визуально допустимый фронт / без артефактов»; граница между классами может потребовать кодбука (например, допускается лёгкий шум, но не двойной фронт). На инференсе для массовой фильтрации логов задаётся порог τ на оценке $P(\omega = 1 | \varphi)$; кривые с $P < \tau$ исключаются из формирования датасета для последующей регрессии концентрации.

Место в конвейере: «сырые логи сеансов» $\rightarrow$ разбор записей $\rightarrow$ расчёт φ $\rightarrow g(\varphi)$ $\rightarrow$ дальнейшая обработка для $\omega = 1$. Таким образом, центральным

результатом практики является обученный классификатор качества линий, а регрессионная модель концентрации может опираться на отдельное обучение и другой кодовый контур.

3. ПРОГРАММА

3.1 Подготовка тестовых данных

Тестовые данные для классификатора формируются из измерительных файлов: для каждой записи извлекается дискретная кривая засветки $y = (y_0, y_1, \dots, y_{N-1})^T$ ($N \geq 2$). Вектор признаков для одной линии задаётся двумерным $\varphi = (k, accuracy_of_line)^T$; целевая переменная для обучения — экспертная метка $\omega \in \{0, 1\}$ (плохая / хорошая линия), задаваемая принадлежностью файла к каталогу «плохих» или «хороших» при сборе выборки.

Признак k (максимальный наклон по модулю). Пусть $\Delta y_j = y_{j+1} - y_j$, $j = 0, \dots, N - 2$. Тогда

$$k = \max\{0 \leq j \leq N - 2\} |\Delta y_j| = \max\{0 \leq j \leq N - 2\} |y_{j+1} - y_j|, \quad (10)$$

Величина k характеризует наибольшую локальную крутизну фронта засветки на развёртке.

Признак *accuracy_of_line*, число провалов. Сначала строится сглаженная кривая скользящим средним с окном $w \in \mathbb{N}$ (параметр DIP_SMOOTH_WINDOW; при $w = 1$ сглаживание отсутствует, $\tilde{y} = y$). Пусть $h = (1/w, \dots, 1/w)^T$ — ядро длины w . Сглаженный профиль получается дискретной свёрткой в режиме совпадения длины с исходным вектором

$$\tilde{y} = y \circledast h, \quad \dim(\tilde{y}) = N, \quad (11)$$

где $\circledast$ — дискретная свёртка с равномерным ядром h длины w ; в реализации используется режим, сохраняющий длину последовательности. Далее вводятся пороги: минимальная глубина провала $\Delta > 0$ (DIP_MIN_DELTA) и нижний порог по уровню сигнала y_{min} (DIP_MIN_Y), ниже которого точки не рассматриваются.

Индекс $i \in \{1, \dots, N - 2\}$ считается провалом, если выполнены условия локального минимума и достаточной глубины:

$$\tilde{y}_i < \tilde{y}_{\{i-1\}}, \tilde{y}_i < \tilde{y}_{\{i+1\}}, \tilde{y}_i \geq y_{min}, \quad (12)$$

$$\min(\tilde{y}_{\{i-1\}} - \tilde{y}_i, \tilde{y}_{\{i+1\}} - \tilde{y}_i) \geq \Delta, \quad (13)$$

тогда есть число таких индексов i (в реализации — целое неотрицательное число, подаётся в модель как вещественный скаляр).

Разбиение на обучающую и контрольную части выполняется с стратификацией по ω , чтобы на тесте сохранялись оба класса; доля теста (например, 20–30 %) и зерно генератора фиксируются для воспроизводимости. Желательно заранее отложить смешанный пак (подпапки good/ и bad/) как «внешний» тест без перекрытия с обучением — так проверяется переносимость на новые файлы.

Рекомендуется фиксировать в приложении к работе: версии файлов данных, параметры w , Δ , y_{min} , состав $\varphi = (k, accuracy_of_line)^T$, гиперпараметры CatBoostClassifier (T , η , глубина), правило порога τ на вероятности класса «хорошая».

3.2 Проведение тестирования

После обучения CatBoostClassifier на train-части на контроле вычисляются вероятности $P(\omega = 1 | \varphi)$ и дискретные предсказания при выбранном пороге. Для непрерывной оценки качества ранжирования строится ROC-кривая и вычисляется ROC-AUC [5].

Отдельно, помимо «внутреннего» теста (разбиение train/test), вводится внешний тест на смешанном пакe файлов фиксированной структуры: каталог, внутри которого находятся две подпапки — good/ (файлы *.log с хорошими линиями) и bad/ (файлы *.log с плохими линиями). Такой тест удобен тем, что моделирует реальную эксплуатацию: в пак можно складывать новые размеченные файлы, не затрагивая обучающий корпус, и регулярно проверять переносимость классификатора. Метрики на mixed pack считаются на всех линиях, извлечённых из файлов обеих подпапок.

Дополнительно полезны: кривая precision–recall при дисбалансе классов; распределение $P(\omega = 1 | \varphi)$ отдельно по $\omega = 0$ и $\omega = 1$ на контроле.

3.3 Анализ результатов тестирования

Практический эксперимент выполнен в программной связке BLA_* (Python, CatBoostClassifier [3], scikit-learn [5, 6]): признаки $\varphi = (k, accuracy_of_line)^T$ извлекались по формулам (10) – (14); обучающая и тестовая (hold-out) выборки формировались из логов в ручную, в каталог BLA_test_pack/good и BLA_test_pack/bad. Для учёта дисбаланса классов (порядка 107 «хороших» и 744 «плохих» линий в полном корпусе) при обучении использовался режим автоматических весов классов Balanced в CatBoost.

На рисунке 1 показан результат работы программы. Отложенная подвыборка при стратифицированном разбиении, доля теста 0,2, фиксированный seed генератора получены значения, близкие к следующим ориентирам: доля правильных ответов (ассигасу) порядка 0,99; F_1 для класса «хорошая» порядка 0,98; ROC-AUC на пороге единицы. На полном смешанном паке (все линии из good/ и bad/, без дополнительного разбиения) метрики также оказались высокими: ассигасу порядка 0,999; F_1 для «хорошей» порядка 0,995; ROC-AUC близок к 1.

```

=== Mixed pack eval: C:\Users\ne4sp\my-universe\dak-cali-ai\BLA_test_pack ===
Files: good=1 bad=1 | lines=851

```

	precision	recall	f1-score	support
bad (0)	1.00	0.01	0.02	744
good (1)	0.13	1.00	0.22	107
accuracy			0.13	851
macro avg	0.56	0.50	0.12	851
weighted avg	0.89	0.13	0.04	851

Рисунок 1 – результат выполнения cli-скрипта программы

ЗАКЛЮЧЕНИЕ

ходе практики решена задача бинарной классификации цифровых кривых засветки рефрактометрического канала на классы «хорошая линия» и «плохая линия» для последующей фильтрации данных при подготовке обучающих выборок. Сформулированы физические и инженерные предпосылки рефрактометрии, описан вектор признаков φ из двух величин: максимального по модулю наклона профиля k и числа провалов `accuracy_of_line` после сглаживания (параметры w , Δ , y_{min}). Реализован консольный конвейер `BLA_*`: загрузка логов через класс `Train`, обучение `CatBoostClassifier` с балансировкой классов, сохранение модели, оценка на отложенной выборке и на смешанном паке каталогов `good/` и `bad/`.

Эксперимент показал высокое качество классификации по отчётным метрикам (`accuracy`, F_1 , ROC-AUC) на полном тестовом паке; анализ важностей признаков выявил доминирование k при отсутствии вариации числа провалов в исходном архиве. Практическая значимость работы — автоматизация отбора линий и снижение доли ручной фильтрации при накоплении новых измерений; ограничение — необходимость проверки обобщения на независимые сеансы и экспертную разметку, не совпадающую с тем же детерминированным правилом.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Резников В.Л., Ящерицын П.И. Смазочно-охлаждающие технологические среды для механической обработки. — М.: Машиностроение, 1990. — 336 с.
2. Friedman J.H. Greedy function approximation: a gradient boosting machine // The Annals of Statistics. — 2001. — Vol. 29, № 5. — С. 1189–1232.
3. Prokhorenkova L., Gusev G., Vorobev A., Dorogush A.V., Gulin A. CatBoost: unbiased boosting with categorical features // Advances in Neural Information Processing Systems. — 2018. — Vol. 31.
4. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning. — 2nd ed. — New York: Springer, 2009.
5. James G., Witten D., Hastie T., Tibshirani R., Taylor J. An Introduction to Statistical Learning with Applications in Python. — New York: Springer, 2023.
6. Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.
7. Born M., Wolf E. Principles of Optics. — 7th ed. — Cambridge: Cambridge University Press, 1999.
8. Gonzalez R.C., Woods R.C. Digital Image Processing. — 4th ed. — Pearson, 2018.
9. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // Proc. 22nd ACM SIGKDD. — 2016. — P. 785–794.
10. Streamlit Inc. Streamlit documentation [Электронный ресурс]. — URL: <https://docs.streamlit.io> (дата обращения: 06.04.2026).
11. Plotly Technologies Inc. Plotly Open Source Graphing Library for Python [Электронный ресурс]. — URL: <https://plotly.com/python/> (дата обращения: 06.04.2026).
12. Machine Learning Implementation for Unambiguous Refractive Index Measurement Using a Self-Referenced Fiber Refractometer // IEEE Journal of Lightwave Technology / IEEE Xplore (по запросу: self-referenced fiber refractometer machine learning). — Указать том, год, страницы по полной библиографической записи из IEEE Xplore при оформлении по ГОСТ.
13. Accuracy Enhancement in Refractive Index Sensing via Full-Spectrum Machine Learning Modeling // Biosensors (MDPI). — 2025. — Vol. 15, № 9. — Статья 582. — URL: <https://www.mdpi.com/2079-6374/15/9/582> (дата обращения: 06.04.2026).
14. Machine learning and metabolic modelling assisted implementation of a novel process analytical technology in cell and gene therapy manufacturing

// Scientific Reports (Nature). — 2023. — Уточнить том, номер статьи по полной записи.

15. Иванов А.А. и др. Prediction of Ethanol Content and Total Extract Using Densimetry and Refractometry // Beverages (MDPI). — 2023. — Vol. 9, № 2. — Статья 31. (Пример связки рефрактометрии с предсказательными моделями; уточнить список авторов по источнику.)